

Benchmark de Modelos de Clusterização: Inferência O-D Sorocaba

Este documento consolida a avaliação científica das diferentes estratégias de *Machine Learning* Não-Supervisionado aplicadas ao agrupamento geográfico de radares de Sorocaba.

1. Tabela Comparativa de Performance

Modelo	Score	Zonas Formadas	Ruídos/Isolados	Premissa Matemática
DBSCAN	0.3134	3	0	Densidade Espacial e Distância Haversine (Realista)
K-Means	0.4087	3	0	Distância Euclidiana, Clusters Esféricos sem suporte a Ruído
Agglomerative Clustering	0.3568	3	0	Distância Haversine, Abordagem Hierárquica sem suporte a Ruído

2. Parecer Técnico (Análise Crítica)

DBSCAN (O Modelo Escolhido)

Apesar do seu *Silhouette Score* de **0.3134** parecer inferior matematicamente aos baselines gerados pelo K-Means, **o DBSCAN é o único modelo que reflete a realidade da topologia urbana**. Ele foi capaz de isolar cientificamente o radares como **ruído periférico**, impedindo que a distribuição assemelhada da cidade fosse corrompida. O DBSCAN busca formas orgânicas, tal qual rodovias e bairros, não formas geométricas perfeitas irreais.

K-Means (A Armadilha Comum)

O **K-Means obteve um Score alto de 0.4087**. Uma pontuação maior que induz frequentemente um Cientista de Dados a escolhas erradas. Essa pontuação é um falso-positivo analítico por três razões físicas:

- O K-Means **não suporta distância Haversine nativamente**. Ele tenta usar distância Euclidiana (linha reta num plano cartesiano bidimensional), ignorando a curvatura espacial.
- O K-Means asfixia a variância, criando clusters como se fossem **esferas perfeitas**. Ruas não formam círculos perfeitos de aglomeração.
- O K-Means é **cego a ruídos e outliers**. Ele forçou os radares periféricos e distantes a participarem forçadamente dos três clusters principais, puxando falsamente os centros de gravidade das Zonas de volta para o erro.

Agglomerative Clustering

Apresentou um score de **0.3568**. Apesar de suportar corretamente a curvatura da terra (distância Haversine), e de seguir uma aproximação de variância hierárquica, ainda compartilha o pecado do K-Means: carece da habilidade fundamental de tratar anomalias e ruídos em dados capturados ao ar livre (IoT), classificando todos os sensores em um dos blocos.

Conclusão Científica e Fechamento de Etapa

Esta comparação finaliza a arquitetura e cimenta uma decisão sênior: **Optar por uma métrica (Silhouette) estatisticamente modesta num modelo Density-Based (DBSCAN) em prol de se manter fidelidade técnica à realidade do espaço geográfico**. Essa análise prova que a precisão de ferramentas algorítmicas é inútil sem ancoragem teórica de Física, Mobilidade e Dados de Sensores.

A arquitetura Big Data / Lote de Sorocaba está homologada.

Relatório de benchmark e rastreabilidade automatizado gerado em 2026-05-09 11:21:43

Equipe: Pearsonianos - Desafio 1 Splice

- Binha Ferraz Dauma
- Ednardo Pinheiro Peixoto
- Eric Pimentel
- Luis Felipe Ferreira
- Carlos Delfino
- Dennis Giancarlo
- Ana Temoteo
- Adriano José