

Documentação Executiva do Projeto: Inferência de Fluxos Origem-Destino com IA

Projeto: Gêmeos Digitais TIC51 | Desafio 1: Mobilidade Urbana em Sorocaba-SP

1. Problema de Negócio e Contexto

A gestão de mobilidade urbana depende da compreensão profunda de como a população se desloca. O desafio proposto exige a inferência de padrões de fluxo Origem-Destino (O-D) a partir de uma base massiva de sensores de tráfego, desprovida de rótulos explícitos de viagem. O objetivo final é traduzir 76 milhões de "pings" de radares em inteligência acionável (Matriz O-D) para subsidiar decisões de políticas públicas (ex: novos trajetos de ônibus e expansão viária).

2. Pergunta Analítica

Como identificar, delimitar e agrupar viagens individuais contínuas em um fluxo de dados de sensores assíncronos, para extrair zonas primárias de Origem e Destino na cidade de Sorocaba?

3. Os Dados e a Engenharia de Estruturação

3.1. Estratégia de Engenharia de Dados (Big Data)

O dataset original fornecido (localizado em `data/00_raw/`) em formato CSV era consideravelmente pesado, ultrapassando os 12 GB, o que inviabilizaria a manipulação convencional em memória RAM (ferramentas como Pandas padrão resultariam em falhas de *Out-Of-Memory*).

Para contornar este gargalo tecnológico, a primeira estratégia adotada foi a **Conversão Estrutural para Parquet**. Essa ação reduziu o tamanho físico do arquivo para **5.15 GB** através de compressão *Snappy* e armazenamento colunar. Acoplada a essa conversão, adotamos o motor de banco de dados **DuckDB**, permitindo a leitura e o processamento matemático do arquivo via streaming (*Out-Of-Core*), processando 76.662.221 registros em meros segundos, sem estourar a memória.

3.2. Aspectos Gerais das Variáveis

A base de dados possui 9 variáveis primárias, que apresentaram os seguintes perfis durante nossa auditoria automatizada:

- `NSerie`, `Endereco`, `Sentido`: Variáveis categóricas que descrevem a identidade, local e direção do sensor.
- `Datatrafego`: Série temporal que registra o momento exato da passagem do veículo. Originalmente gravada como texto (VARCHAR), exigiu conversão para `TIMESTAMP` matemático no formato numérico brasileiro (`%d/%m/%Y %H:%M:%S`).

- `Latitude` e `Longitude`: Coordenadas espaciais vitais para o projeto. Apresentaram um erro crônico de tipagem: estavam no formato texto com mistura de vírgulas e pontos decimais. Um pipeline foi construído para higienizar, expurgar as vírgulas e aplicar o `cast` para `DOUBLE`.
- `Placa`: O hash criptográfico anonimizado de 64 caracteres que identifica o veículo. Diferente de um ambiente controlado, identificamos **3.043.894 veículos únicos** operando no trimestre.
- `Velocidade 1` e `Velocidade Regul`: Variáveis numéricas contínuas medindo o comportamento dinâmico da via.

3.3. A Prova dos 61 Sensores (Infraestrutura Divergente)

O documento oficial do edital cita categoricamente a existência de "50 pontos de coleta ativos". No entanto, nossa equipe submeteu a base a **duas análises de validação cruzada independentes**:

1. **Extração de Hashes Únicos:** O comando `COUNT (DISTINCT)` extraiu 61 strings únicas para a variável `NSerie`.
2. **Agrupamento Volumétrico de Prova:** Para afastar falsos positivos, executamos um agrupamento (`GROUP BY NSerie`) listando a volumetria absoluta de cada sensor. O teste comprovou os 61 sensores e revelou o padrão: os sensores do topo (`10xx`) capturam mais de 4 milhões de registros cada, enquanto 11 sensores da base da lista (`80xx`) possuem volumes muito baixos (ex: 10 mil leituras).

Isso indica falha na documentação do edital e a presença oculta de equipamentos periféricos (como radares móveis, sensores em teste ou câmeras de muralha digital) que foram absorvidos em nossa modelagem sem perda de dados.

4. Definição Categórica da Variável-Alvo

Em Ciência de Dados, problemas de clusterização (Não-Supervisionados) não possuem uma variável-alvo ("Y") pré-rotulada clássica. Nosso desafio primário foi **criar as variáveis matemáticas** que alimentariam o algoritmo de Machine Learning.

Para não dar margens a más interpretações na banca, definimos a extração dos dados alvo (Features) através da heurística de **Sessões de Trajetória (Trip Sessions)** com base em uma **Janela de Inatividade**:

1. **A Regra de Delimitação:** Se a placa 'X' passa por um sensor e desaparece do radar de toda a cidade por **mais de 45 minutos**, o motor de banco de dados encerra aquela viagem. O último sensor detectado torna-se o **Destino**. O próximo reaparecimento da placa será classificado como uma nova **Origem**.
2. **As Variáveis-Alvo do Algoritmo:** As features estruturadas que alimentam o nosso Machine Learning são **exclusivamente geoespaciais**. O algoritmo consumirá:
 - `[origem_lat, origem_lon]`
 - `[destino_lat, destino_lon]`

Esta lógica estruturada extraiu **2.1 milhões de viagens contínuas puras** (com duração média de 6.3 minutos) apenas na primeira semana de janeiro, transformando 76 milhões de pings desconexos na nossa verdadeira base de Inteligência Artificial.

5. Estratégia de Inteligência Artificial (Machine Learning)

1. **Passo 1 - Engenharia de Features (Heurística):** O pipeline em DuckDB calculou o Delta de Tempo (*Window Functions*) para extrair as matrizes O-D em frações de segundos.
2. **Passo 2 - IA Não-Supervisionada (Clusterização Espacial):** Com as coordenadas de Origem e Destino geradas, a inteligência da solução aplica o **DBSCAN** (Density-Based Spatial Clustering of Applications with Noise) ou **K-Means Espacial**.
 - *O Porquê Técnico:* 2.1 milhões de rotas puras não geram decisão de negócio. O algoritmo de ML agrupará pontos de paradas muito próximos, fundindo-os em macro **Zonas de Densidade**. Ele varre o mapa identificando onde há aglomeração matemática de partidas e chegadas.

6. Métricas Oficiais de Avaliação Adotadas

Dado o caráter Não-Supervisionado (Clusterização) do projeto, descartamos formalmente métricas de classificação categórica (como F1-Score ou AUC-ROC) e adotaremos as seguintes métricas científicas:

1. **Silhouette Score (Coeficiente de Silhueta):** Métrica matemática que varia de -1 a 1. Ela medirá o quão coesos estão os nossos clusters de zonas da cidade (distância intra-cluster) em relação a zonas vizinhas (distância inter-cluster). Um score positivo próximo de 1 indica que o agrupamento espacial das origens/destinos funcionou com excelência.
2. **Avaliação Georreferenciada (Inspeção Qualitativa):** Avaliação de "Falsos Positivos" semânticos no mundo real. O modelo será validado sobrepondo as "Zonas" criadas pela IA em um mapa rodoviário real de Sorocaba. Se a IA gerar um polo de fluxo intenso no meio de um lago ou em área de mata fechada, o modelo falhou em coerência e precisará de ajustes no raio de distância do cluster.

7. O Produto Final: MVP a ser Apresentado

Nossa entrega de Produto Mínimo Viável (Sábado) não será apenas um notebook com códigos abstratos, mas uma demonstração de Inteligência Acionável para gestão pública. O MVP consistirá de:

1. **Pipeline Transparente:** Um Notebook limpo mostrando a rápida transformação do caos de 76 milhões de linhas para a extração purificada das viagens (A Auditoria e a Matriz O-D).
 2. **O Mapa de Calor Interativo (Heatmap Georreferenciado):**
 - Utilizando bibliotecas como `Folium` ou `Kepler.gl`, apresentaremos o mapa de Sorocaba plotado com as verdadeiras "Zonas de Calor" reveladas pelo algoritmo de Clusterização.
 - Haverá distinção visual clara entre as Zonas de **Alta Origem** (Pólos residenciais matinais) e Zonas de **Alto Destino** (Pólos comerciais/industriais).
 - **Insights Acionáveis:** A apresentação culminará na demonstração de 2 ou 3 grandes fluxos anômalos ou hiper-densos descobertos pela IA, servindo de base teórica imediata para o redirecionamento de linhas de ônibus urbanos.
-

Equipe: Pearsonianos - Desafio 1 Splice

- Binha Ferraz Dauma
- Ednardo Pinheiro Peixoto
- Eric Pimentel
- Luis Felipe Ferreira
- Carlos Delfino
- Dennis Giancarlo
- Ana Temoteo
- Adriano José