

Relatório Técnico: Auditoria e Pipeline de Dados (Sorocaba 2026)

Este documento sumariza os resultados da varredura automatizada (*Data Profiling*) executada pelo script `scripts/audit_data.py` utilizando o **DuckDB** sobre a base de dados bruta, e documenta as camadas de transformação de engenharia de dados aplicadas em sequência para viabilizar a modelagem de Inteligência Artificial.

1. Informações Estruturais Básicas (Camada Raw)

- Arquivo Fonte:** `DADOS_SOROCABA_JANEIRO_A_ABRIL_2026.parquet`
- Volume de Armazenamento:** 5.15 GB
- Total de Registros (Linhas):** 76.662.221
- Tempo de Execução da Auditoria:** 14.05 segundos

Dicionário de Tipagem Bruto (Schema)

Coluna	Tipo de Dado no Parquet	Status da Auditoria
NSerie	VARCHAR	OK
Endereco	VARCHAR	OK
Sentido	VARCHAR	OK
Datatrafego	VARCHAR	Formato de Data
Latitude	VARCHAR	CRÍTICO
Longitude	VARCHAR	CRÍTICO
Placa	VARCHAR	CRÍTICO
Velocidade 1	DOUBLE	OK
Velocidade Regul	DOUBLE	OK

2. Análise de Completude (Nulos)

Foi feita uma varredura para identificar valores do tipo `NULL`.

Coluna	Qtd Nulos	% Nulos
Todas as 9 colunas	0	0.00%

[!WARNING]

A ausência total de nulos (0%) em uma base de IoT/Sensores de 76 milhões de registros indica que os dados brutos já sofreram uma transformação prévia (provavelmente durante a conversão do CSV original) onde os nulos foram imputados, dropados ou substituídos por "strings em branco".

3. Validação de Fronteiras e Cardinalidade

3.1 Fronteiras Espaço-Temporais

Métrica	Valor Mínimo	Valor Máximo	Observação de Auditoria
Tempo (<code>Datatrafego</code>)	01/01/2026 00:00:01	31/03/2026 23:59:59	Cobertura exata do 1º Trimestre.
Latitude	-23,44511	-23.5324	Inconsistência de Formato
Longitude	-47,43921	-47.5146	Inconsistência de Formato

[!CAUTION]

As coordenadas geográficas estavam gravadas como `VARCHAR` e misturavam vírgulas e pontos como separador decimal, exigindo um pipeline rigoroso de sanitização.

3.2 Cardinalidade Populacional e de Infraestrutura

Entidade	Contagem Distinta
Veículos Únicos (<code>Placa</code>)	3.043.894
Sensores Únicos (<code>NSerie</code>)	61

[!NOTE]

Identificamos mais de **3 milhões de veículos únicos**, validando nosso fluxo O-D como um reflexo fiel da mobilidade urbana.

Além disso, o documento do edital afirmava existirem **50 pontos ativos**, mas a base revela **61 sensores únicos**, apontando a presença de radares móveis ou dados fantasmas.

4. Pipeline de Engenharia de Dados Pós-Auditoria

Com as anomalias diagnosticadas, a base crua foi submetida a um pipeline sequencial de tratamento estrutural (*Data Engineering*) que abandonou a abordagem de amostras simples em favor da extração em camadas lógicas completas:

4.1 Camada Bronze (Sanitização e Tipagem)

- **Script:** `scripts/clean_bronze.py`
- **Ação:** O dataset integral de 76 milhões de linhas foi reprocessado via DuckDB.
- **Transformações:** As colunas `Latitude` e `Longitude` tiveram suas vírgulas substituídas por pontos e sofreram cast para o tipo matemático `DOUBLE`. A coluna `Data trafego` foi parseada de texto para `TIMESTAMP`.
- **Resultado:** Geração do arquivo limpo
`data/01_bronze/DADOS_SOROCABA_BRONZE.parquet` (5.20 GB).

4.2 Camada Silver (Segmentação de Viagens / Matriz O-D)

- **Script:** `scripts/trip_segmentation.py`
- **Ação:** Aplicação da Heurística de **Janela de Inatividade de 45 minutos** (*Trip Sessions*) sobre a base Bronze, extraíndo a primeira semana de Janeiro como prova de conceito.
- **Transformações:** Funções de Janela (*Window Functions*) calcularam o *delta* temporal de cada veículo, demarcaram o fim de cada viagem e extraíram a latitude e longitude exatas da Origem e do Destino.
- **Resultado:** Geração da Matriz Origem-Destino
`data/02_silver/matriz_od_amostra_1semana.parquet`, contendo **2.143.327 de viagens reais** com duração média de 6.3 minutos, estruturando o caos de pontos assíncronos na verdadeira base de Machine Learning.